

- 题目：cninfo 监管公告单公告结构化抽取
- 问题：把监管类公告中的监管对象、问题点、监管动作与要求抽成结构化表，支持后续风险点统计与证据回溯
- 口径：单公告抽取，一条记录 = 一份公告；不做问询函一回复跨公告闭环匹配
- reply 公告只抽取当前回复文本中实际写出的事项，不判断是否逐项回应原函

- 数据源：cninfo 公开公告查询接口 + cninfo 公告 PDF
- 时间范围：2023-01-01 ~ 2026-05-11
- 市场：沪深两市
- 关键词与过滤：问询/关注函、回复、监管措施、警示函、整改报告；排除募集说明书、法律意见书、核查意见等附件型文本
- 当前样本：metadata=120，pdf=120

- 申请：标准档 1.0
- 理由：
  - 目标规模 120 份 PDF，落在 80–150 标准档区间
  - 包含 collect / download / parse / route / extract / validate / report 全流程
  - 有 section checking、evidence 校验、字段级人工评估
  - 未进入多文档 linking，因此不升级为闭环挑战档

- 顶层字段：doc\_id / stock\_code / stock\_name / market / publish\_date / announcement\_title / doc\_type / source
- targets[]：name / role / target\_type / evidence
- issues[]：issue\_type / issue\_summary / is\_violation\_related / evidence
- actions[]：action\_type / action\_source\_type / deadline / required\_disclosure / evidence
- 白名单：
  - target\_type：listed\_company / controlling\_shareholder / actual\_controller / director / supervisor / executive / intermediary / subsidiary / shareholder\_other / other
  - issue\_type：information\_disclosure / internal\_control / fund\_occupation / related\_party\_transaction / raised\_funds / financial\_irregularity / mna\_restructuring / other
  - action\_type：inquiry\_reply\_required / rectification\_required / warning\_letter / supervisory\_talk / order\_correction / disclosure\_update\_required / written\_report\_required / other
  - action\_source\_type：regulator\_required / company\_committed / unclear
- null rule：没有证据就 null 或空列表，不做推断补全

- 解析工具：MinerU API，禁止本地 fallback
- 当前解析结果：parsed\_docs=116/120，解析成功率 96.7%
- section routing：对每篇文档生成目标 section，并注入 [Page N]
- routing 线索：标题语境 + 现回复如下/经查/存在以下问题/决定对 等锚点 + 一、二、三 编号结构 + 问题列表/整改提示
- 当前 routing：sections=116
- section 检查统计：found 201/232，ok 183/232
- 长文本处理：reply/监管报告常很长，实际抽取前按页切片并优先保留前 5 个 page block，减少 LLM 超时；因为核心监管对象、问题和要求通常集中在前几页正文

- collect -> metadata.csv
- download -> data/pdf/\*.pdf
- parse -> parsed\_docs.jsonl
- route\_sections -> sections.jsonl
- extract -> outputs/tmp/extracted.jsonl
- validate -> outputs/results/final\_results.jsonl
- report -> outputs/reports/eval\_report\_final.md
- 当前全量结果：extract ok=115/116 ， final\_results=115 ， 剩余 1 条为远端 LLM API 500 失败

- 固定样本：doc\_id=1225290815
- 标题：关于收到江苏证监局警示函的公告
- 展示路径：
  - metadata.csv 中的 doc\_id / pdf\_url
  - data/pdf/1225290815.pdf
  - sections.jsonl 中带 [Page 1] 的正文
  - final\_results.jsonl 中对应结构化结果
- 现场解释 3 个字段：
  - regulator\_name = 中国证券监督管理委员会江苏监管局
  - issues[0].issue\_type = information\_disclosure
  - actions[0].action\_type = warning\_letter
  - actions[0].action\_source\_type = regulator\_required

- 最终结果数：115
- 人工评估：20 篇 PDF，105 行字段级评估
- 准确率：
  - doc\_type : 16/20 = 80.0%
  - regulator\_name : 14/14 = 100.0%
  - targets : 21/27 = 77.8%
  - issues : 17/20 = 85.0%
  - actions : 21/24 = 87.5%
  - evidence\_correct : 74/85 = 87.1%
- 主要错误：
  - target\_missing : 6
  - doc\_type\_wrong : 4
  - action\_type\_misclassified : 2
  - issue\_summary\_incorrect : 2



- 先按老师意见把项目边界锁成单公告抽取
- schema 从粗粒度数组升级为带枚举和 evidence 的结构对象
- actions 增加 action\_source\_type，区分监管要求和公司承诺
- collect 增加标题过滤与附件排除词，减少“说明书/法律意见书”混入
- router 改为优先遵循标题推断 section 类型，避免 reply 文档被路由到监管措施 section
- extract 增加并发、超时重试、长文本截断和坏 item 清洗
- validator 增加枚举合法性和 evidence/page\_no 硬校验
- 2026-06-08 新增优化：reply 路由跳过目录页；prompt 强化 listed\_company / deadline / action\_type 规则；validator 基于 evidence 修正明显错误的 action\_type 并清除无证据支持的 deadline
- 2026-06-13 新增优化：对 10 条 extract 失败样本做 900 秒延时重试，补回 9 条；同时修正 validator 的 action\_type 优先级，避免把公司整改承诺误修成警示函动作

- 先与 AI 写清楚目标、输入输出、约束、done definition，再让 AI 落代码，而不是直接让 AI 自由生成
- 关键硬约束：
  - 只用 cninfo 元数据和 cninfo PDF
  - MinerU 失败就报错，不允许 fallback
  - evidence 必须来自输入原文，缺证据就 null
- AI 的作用：搭流水线骨架、生成 schema/prompt、补日志与报告
- 人的作用：锁边界、审查样本、核对 evidence、做字段级人工评估、修正口径
- 典型错误：
  - doc\_type 把“延期回复公告”错分成 attention\_letter / inquiry\_letter / other
  - reply / 整改报告里漏抽 target 或 issue
  - deadline 误抽签字日期